1ère Année Master GL (S3) Module : **Requêtes conjonctives**

TD 3: MapReduce

Exercice 1 :

Soit un grand document de type texte. Nous souhaitons réaliser quelques analyses sur son contenu. Plus particulièrement, catégoriser les mots en 4 catégories :

- Minuscule : 1 lettre ;
- Petit : 2 à 4 lettres ;
- Moyen : 5 à 9 lettres ;
- Grand : plus de 10 lettres

Travail à faire :

- Donner le schéma détaillé des opérations Map-Reduce
- Ecrire en pseudo code les fonctions Map et Reduce permettant de retourner le nombre de mots dans chaque catégorie.
- Traduire le pseudos codes en langage java.

Exercice 2 :

On reçoit d'un fournisseur une livraison de fruits (pommes, ananas, oranges, etc.). On décide d'effectuer un test qualité en leur donnant 0 ou 1 pour les critères suivants (trop mûr, tâché, déformé, etc.). Pour chaque espèce de fruit, on veut calculer la proportion de fruits trop mûrs. Comment faire avec MapReduce?

- Présentez avec explication) les taches Map-Reduce permettant de retourner le résultat souhaité à l'aide d'un schéma détaillé.
- Ecrivez en pseudo-code (algorithmes) les fonctions Map et Reduce.
- On veut faire le même calcul pour tous les critères. Comment faire ?

Exercice 3 : Comptage de mots

On se propose de compter le nombre d'occurrences de chaque mot dans une collection de documents.

1- Dans la fonction Map, comment définir le couple (key, value).

2- Ecrire l'algorithme de la fonction Map.

3- Ecrire l'algorithme de la fonction Reduce.

4- Donner un exemple qui illustre le fonctionnement MapReduce.

Exercice 4:

Soit une entreprise de grande distribution qui souhaite faire des statistiques sur les ventes des dix dernières années en ce début d'année. Elle possède une base de données stockée sur un système HDFS ; ne sera considérée que la partie de la base qui contient les données des dix années précédentes. Ces données sont stockées dans des fichiers textes. Chaque ligne d'un fichier correspond à la vente d'un produit et on peut y trouver des informations comme :

- la date (et l'heure) de vente
- le nom du magasin où le produit a été vendu
- le prix de vente
- la dénomination du produit
- la catégorie du produit (ex : fruits et légumes, électroménager, jouet, ...)

Exemple : 17_12_2017 hello 700 carte SD électronique

Écrivez le pseudo-code du programme map-reduce permettant de calculer le chiffre d'affaire de l'entreprise pour chacune des années précédentes, c'est à dire la somme totale des ventes des 12 mois de l'année considérée.

Exercice 5: ventes dans un magasin

Nous disposons de l'historique de vente sur plusieurs années d'un magasin. Chaque enregistrement de la liste correspond à une vente de plusieurs articles. Les seules données qui nous intéressent en l'occurrence sont les noms des articles, leur prix ainsi que la quanti té vendue. Notre objectif est d'utiliser MapReduce pour calculer le prix de vente total et la quantité vendue par produit.

Ecrire les algorithmes des fonctions Map et Reduce.